Efficient Character-level Document Classification by Combining Convolution and Recurrent Layers

Abstact

연구의의
기존 문서분류는 Word-level에서 이루어졌습니다. 이 연구는 Character-level input 에 대하여, encoding 과정에서 CNN과 RNN을 이용한 NN 아키텍쳐를 구성했습니다.

기존 Character level 연구와의 차이점
Character-level Convolutional Networks for Text Classification에 RNN을 더해서 훨씬 적은 파라미터를 활용하여 성능을 만들어 냈습니다.

Introduction

Word level의 한계점

- Statistically inefficient
  - 각각의 토큰들은 분리되고 동일한 수의 파라미터를 가지게 됩니다. 하지만 많은 단어들은 같은 root, prefix, suffix를 공유합니다.
- out-of-vocabulary word
  - 단어장 외에 있는 단어들은 token으로 인식이 안됩니다. Word-level에서는 unknown token으로 분류하게 됩니다. 하지만 이러한 문제는 훈련된 모델을 다른 도메인에서 사용할 시에, 문제가 됩니다.
- Missing spell
  - social network 같은곳에 있는 축약어나, 오타등을 잘 못잡게 됩니다.
- reference
  - https://www.edwith.org/deepnlp/lecture/29225/ (https://www.edwith.org/deepnlp/lecture/29225/)

기존의 Character level 방법론

- Character-level Convolutional Networks for Text Classification (Zhang et al., 2015)
  - 다중 convolution layer를 구성하고, max-pooling을 하였다. 각 layer는 우선적으로 feature를 small 부터 뽑아낸다. 마지막 컨볼류션 레이어는 백터의 모양을 flatten하게 activation 시킨다. 그 다음에 fully connected layer로 연결한다.
  - 한계점 : 각 convolution layer의 Receptive field가 작아서(3,7), 네트워크의 layer가 input sequecne의 long-term dependency를 고려하여 커져야합니다.

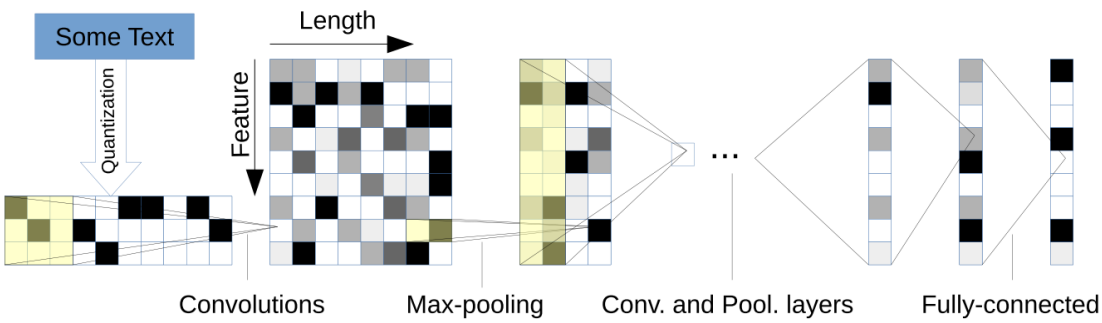

- Very deep convolutional network
  - 6개의 convolution layer 와 2개의 fully-connected layer의 연결로 구성하였다.

- 한계점 : 파라미터 수의 급격한 증가가 있다.

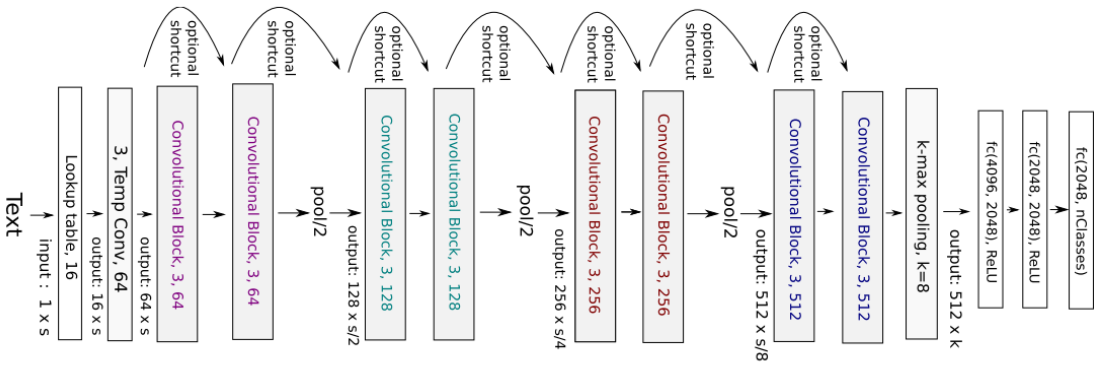

이 논문의 포인트

위에서 언급한 Character-level sequence의 비효율을 해결하기위해서 이 논문에서는 CNN과 RNN의 결합을 소개한다.이 결합 모델은 single recurrent layer 와 CNN 으로 구성되어 있다. RNN의 경우 GRU또는 LSTM의 사용을 통해 long-term dependency를 해결한다. 또한 CNN이 더 적은 컨볼루션 레이어를 사용하게 한다.

Evaluation

Character-level Convolutional Networks for Text Classification 에서 제시한 8개의 large-scale document classification task를 해보고자한다. 8개의 문서분류 문제를 풀어보고, Character-level convolutional networks for text classification와 성능 비교해보자고 한다. 더 적은 모델을 통해서, 비슷한 성능을 내는것을 목표로 한다.

Basic Building Blocks: Neural Network Layers

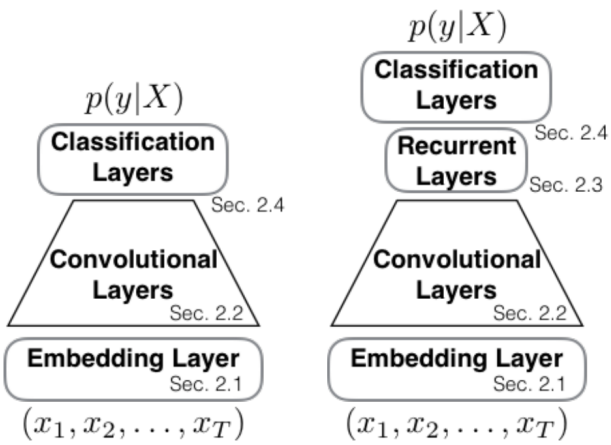

Embedding Layer

- $e_t = Wx_t$
- 각 문서들은 one-hot vector의 sequence로 나타냅니다.
- 학습된 weight matrix가 W입니다.

Convolution Layer

Recurrent Layer

- 이전 hidden step의 input을 받아서 다음번 step의 output으로 내보냅니다.
- Recursive function
- $h_t = f(x_t, h_{t-1})$
- $h_t = tanh(W_x x_t + U_h h_{t-1})$,
- NLP 에서 RNN은 문장의 정보를 시간의 순서에 따라 압축 할 수 있습니다.

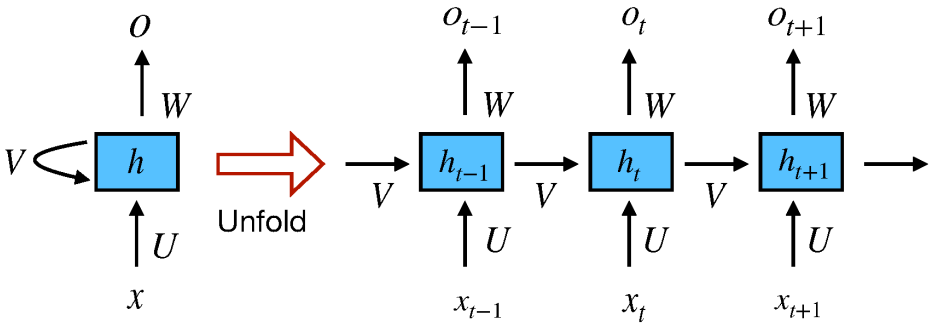

LSTM & GRU

- RNN은 문장이 많이 길어질 수록 고정된 메모리에 압축된 정보를 담아야 하기 때문에, 앞에서 학습한 정보를 잊습니다. 이는 곧 정보의 손실을 뜻합니다.
- LSTM 은 이를 해결하기 위해 cell state를 RNN에 추가합니다
- input,output, forget gates and candidate memory cell 됩니다.
- $f_t = \sigma(W_f x_t + U_f h_{t-1})$
  - '과거 정보를 잊기'를 위한 게이트입니다. h_{t-1}과 x_t를 받아 시그모이드를 취해준 값
- $\tilde{c}_t = tanh(W_c x_t + U_c h_{t-1})$
- $i_t = \sigma(W_i x_t + U_i h_{t-1})$
  - '현재 정보를 기억하기' 위한 게이트입니다.
- $o_t = \sigma(W_o x_t + U_o h_{t-1})$

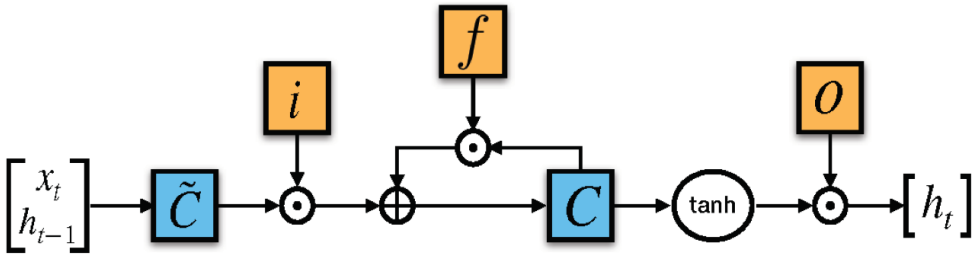

(1) Long Short-Term Memory

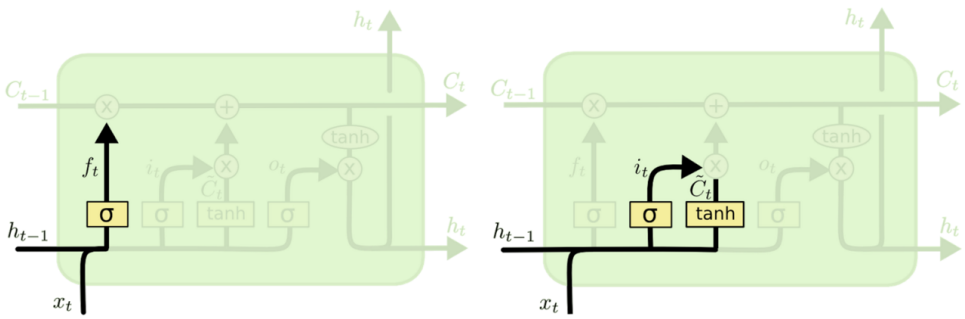

Bidirectional Recurrent Layer

- 또한 토큰을 순차적으로 하나씩 읽어야 하기 때문에, 훈련 할때 속도가 기타 네트워크 보다 느립니다.
- Bidirection RNN 은 양쪽 방향으로 전파시킨다음에 concat 합니다.

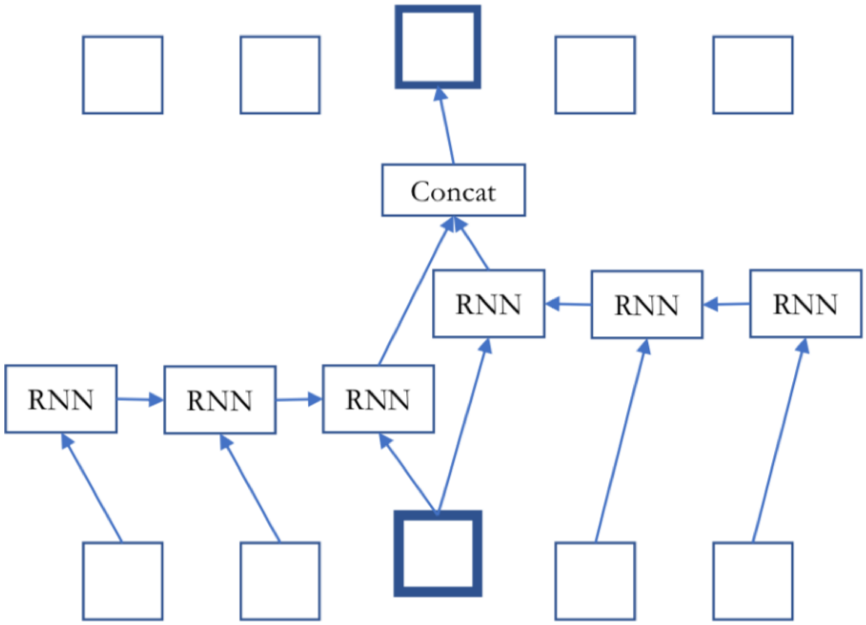

Classification Layer

- Classification 을 위해 logistic regression 을 사용하였습니다.
- 위 Convolution layer 와 Recuurent layer 의 결과가 문장의 길이 D 에 따른 다양한 길이를 가진 sequence를 반환해도 fixed-dimension의 vector를 얻을수 있습니다.

- reference
  - https://nlpoverview.com/#4 (https://nlpoverview.com/#4)
  - https://ratsgo.github.io/natural%20language%20processing/2017/03/09/rnnlstm/ (https://ratsgo.github.io/natural%20language%20processing/2017/03/09/rnnlstm/)
  - https://adeshpande3.github.io/adeshpande3.github.io/A-Beginner's-Guide-To-Understanding-Convolutional-Neural-Networks/ (https://adeshpande3.github.io/adeshpande3.github.io/A-Beginner's-Guide-To-Understanding-Convolutional-Neural-Networks/)

Model Setting

Model	**Embedding Layer** Sec. 2.1		**Convolutional Layer** Sec. 2.2				**Recurrent Layer** Sec. 2.3
	$\|V\|$	d	d'	r	r'	ϕ	d'
C2R1DD	96	8	D	5,3	2,2	ReLU	D
C3R1DD				5,5,3	2,2,2		
C4R1DD				5,5,3,3	2,2,2,2		
C5R1DD				5,5,3,3,3	2,2,2,1,2		

Table 2: Different architectures tested in this paper.

Model Describtion

- Vocabulary 은 96개의 단어로, 대소문자, 숫자, ?!, 공백까지 포함합니다.

- 단어 embedding size는 8 입니다.
- Convolution layer의 경우 2~5개를 배치합니다.
- d' = 128 짜리 filter를 적용합니다. AG, Yahoo의 경우 1024 filter로 실험을 추가해봅니다.
  - Filter를 128개 사용한다고 합니다.
  - Filter 는 detect하고자 하는 feature에 대한 내용
- Receptie field size는 r로 설정하며, depth에 따라 5,3이 됩니다.
  - Receptive Field는 Filter size로 진행하면서 detect되는 실제 값
- Max pooling size r'은 2로 합니다.
- ReLU 씁니다.
- Recurrent layer의 경우, single layer에 birectional LSTM을 모든 모델에 적용합니다. Hidden state는 128의 차원을 가집니다.
- Dropout 을 사용합니다.
  - Convolution layer 와 Recurrent Layer 모두 사용합니다.
- AdaDelta with ρ = 0.95, ϵ = 10−5
- batch size of 128.
- Gradient 가 L2 norm에서 5보다 커질때, rescale 합니다.
- Early stopping 합니다.
  - patience value를 도입합니다.
  - 현재 상태에서 가장낮은 validation loss가 0.5보다 낮을시, patience 를 2배로 확장합니다.
  - epoch가 patience value 보다 커지면 학습을 멈춥니다.

Experiment Setting

Data set	Classes	Task	Training size	Test size
AG's news	4	news categorization	120,000	7,600
Sogou news	5	news categorization	450,000	60,000
DBPedia	14	ontology classification	560,000	70,000
Yelp review polarity	2	sentiment analysis	560,000	38,000
Yelp review full	5	sentiment analysis	650,000	50,000
Yahoo! Answers	10	question type classification	1,400,000	60,000
Amazon review polarity	2	sentiment analysis	3,600,000	400,000
Amazon review full	5	sentiment analysis	3,000,000	650,000

Table 1: Data sets summary.

- Task 200,000 ~ 4,000,000개의 문서를 sentiment analysis, ontology classification, Question type classification, news categorizeation 등을 준비했다.

Result

			Our Model			(Zhang et al., 2015)		
Data set	# Ex.	# Cl.	Network	# Params	Error (%)	Network	# Params	Error (%)
AG	120k	4	C2R1D1024	20M	8.39/**8.64**	C6F2D1024	27M	-/9.85
Sogou	450k	5	C3R1D128	.4M	4.82/**4.83**	C6F2D1024⋆	27M	-/4.88
DBPedia	560k	14	C2R1D128	.3M	1.46/**1.43**	C6F2D1024	27M	-/1.66
Yelp P.	560k	2	C2R1D128	.3M	5.50/5.51	C6F2D1024	27M	-/**5.25**
Yelp F.	650k	5	C2R1D128	.3M	38.00/**38.18**	C6F2D1024	27M	-/38.40
Yahoo A.	1.4M	10	C2R1D1024	20M	28.62/**28.26**	C6F2D1024⋆	27M	-/29.55
Amazon P.	3.6M	2	C3R1D128	.4M	5.64/5.87	C6F2D256⋆	2.7M	-/**5.50**
Amazon F.	3.0M	5	C3R1D128	.4M	40.30/40.77	C6F2D256⋆	2.7M	-/**40.53**

- CCRRFFDD refers to a network with C convolutional layers, R recurrent layers, F fully-connected layers and D dimensional feature vectors
- Classes 의 수가 증가할수록, 우리의 모델은 더 좋은 퍼포먼스를 낼 수 있습니다.
- 더 적은 pooling layer를 사용하면서 구체적인 정보를 더 보존합니다.
- 적은 데이터 사이즈에서 더 잘 작동합니다.
- 컨볼루션 레이어는 2~3개일때 가장 잘 작동합니다
- 필터갯수의 증가는 파라미터 갯수 증가에 비해 성능개선이 약합니다

Conclusion

제안한 모형은 class 숫자 증가에 따라, 데이터셋이 적을수록, 그리고 컨볼루션 레이어가 2~3개일때 가장 잘 작동했습니다.

Q&A

Q. NLP에서 RNN레이어의 Dropout 방법론?

- layer norm
- recurrent dropout
- variational dropout
  - 타임스탭별로 얻어가야한다.
  - 배치안에서 계산해야한다.

Q. 자연어 처리에서의 Data Argmentation을 어떻게 하나요?

- argmentation이 잘못되면 문장의미가 깨진다.
- 유의어 기반으로 교체한다.
- 번역모델로 argmentation 하는게 좋을 것이다.

- https://arxiv.org/abs/1602.00367 (https://arxiv.org/abs/1602.00367)

In [ ]: